

MAD-CB



Projeto Final – Mudanças

- Para melhor comportar com nosso progresso em estatística e R
- Usaremos “Gapminder” como fonte de dados para os projetos
- Gapminder
 - ▶ Fundação sueca que trata de questões sociais e econômicos importantes
 - ▶ É um site de dados e ferramentas para a apresentação deles
 - ▶ Baseado na premissa que pessoas podem entender dados importantes melhor se são acompanhados com um pouco de drama

Projeto – Passo 1

- Formar grupos (max 3 pessoas)
- Escolher uma base de dados de Gapminder que o grupo acha interessante
 - ▶ www.gapminder.org/data/
- Entregue email para mim antes no 10 de março (sexta que vem)
 - ▶ Nomes dos membros do grupo
 - ▶ Base de dados que o grupo vai analisar

Projeto – Passo 2

- Converter a base de Excel para R
- Preparar os dados para a análise
 - ▶ Limpeza; tidy data
- Fazer uma análise exploratória da base
 - ▶ Estatísticas
 - ▶ Visualizações
- Data limite: 31 de março

- Fazer apresentação na aula do projeto
 - ▶ Quais questões tratadas nos dados vocês podem responder
 - ▶ Quais técnicas de análise usaram para tirar essas conclusões
 - ▶ Quais duvidas restam a ser resolvidos
- Escrever um relatório conciso resumindo o projeto e as conclusões
 - ▶ Data limite: 12 de maio

Inferência – Usando Probabilidade para Entender Dados

Teorema de Limite Centrale

- Jogar uma moeda de um real 10.000 vezes e ver quantos CARAS resultam
- Assumimos que temos uma moeda justa
 - ▶ $p(\text{CARA}) = p(\text{COROA})$
- Para simular as jogadas, usamos a distribuição binomial
- Distribuição Binomial
 - ▶ 2 resultados possíveis (Sim/Não, V/F, Cara/Coroa)
 - ▶ Pode repetir o experimento n vezes
 - ▶ Experimentos “Bernoulli”
- Estimador da verdadeira probabilidade de jogar CARA

Cara



Coroa



$$p(\text{Cara}) \approx \hat{p}(\text{Cara}) = \frac{\# \text{ de CARAS observadas}}{\# \text{ de jogadas}}$$

Jogada com 2 Moedas

- Vamos começar com a jogada de 2 moedas
- Cada experimento vai ser a soma do número das Caras (H)
- Possibilidades
 - ▶ $\{T, T\} = 0$
 - ▶ $\{H, T\}, \{T, H\} = 1$
 - ▶ $\{H, H\} = 2$
- Código para produzir 10.000 resultados:

```
pr <- .5 # moeda justa: 50/50 chance de jogar um CARA
n <- 10000 # experimentos
k <- 2 # 2 moedas
moedaProb <- rbinom(n, k, pr)
```

```
## r<dist>() - função para criar números aleatórios
## dado o número de experimentos (n) e das moedas(k)
```

Início de moedaProb – Número de Caras por Experimento


```
moedaProb[1:100]
```

```
##      [1] 2 0 0 2 0 1 1 2 2 2 2 0 0 2 0 1 0 1 2 0 1 0 2 1 1 1 0 0 2 0 2 1 1
##     [36] 0 1 0 1 2 0 1 1 1 1 1 1 1 1 1 2 0 1 0 1 2 2 1 1 1 2 1 2 1 1 2 0 1
##     [71] 1 1 2 1 1 2 0 0 2 1 2 1 0 1 2 2 0 0 2 0 2 1 1 1 1 0 2 1 0 1
```

Probabilidade com 2 Moedas

```
titleline <- paste("p de Jogar Caras com", k, "Moedas")  
plot(table(moedaProb)/n, type = "b", col = "blue",  
      xlab = "Número de Caras", ylab = "Probabilidade",  
      main = titleline)
```

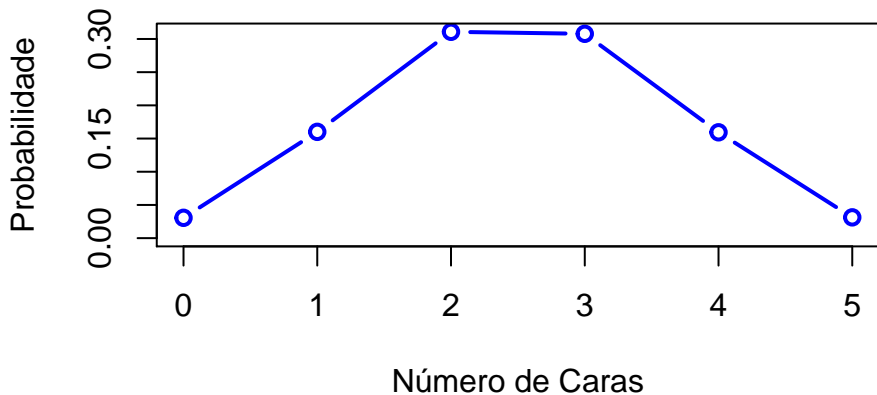
p de Jogar Caras com 2 Moedas



Probabilidade com 5 Moedas

```
titleline <- paste("p de Jogar Caras com", k, "Moedas")  
plot(table(moedaProb)/n, type = "b", col = "blue",  
      xlab = "Número de Caras", ylab = "Probabilidade",  
      main = titleline)
```


p de Jogar Caras com 5 Moedas



Probabilidade com 30 Moedas

```
titleline <- paste("p de Jogar Caras com", k, "Moedas")  
plot(table(moedaProb)/n, type = "b", col = "blue",  
      xlab = "Número de Caras", ylab = "Probabilidade",  
      main = titleline)  
abline(v = 15, col = "red", lwd = 3)
```

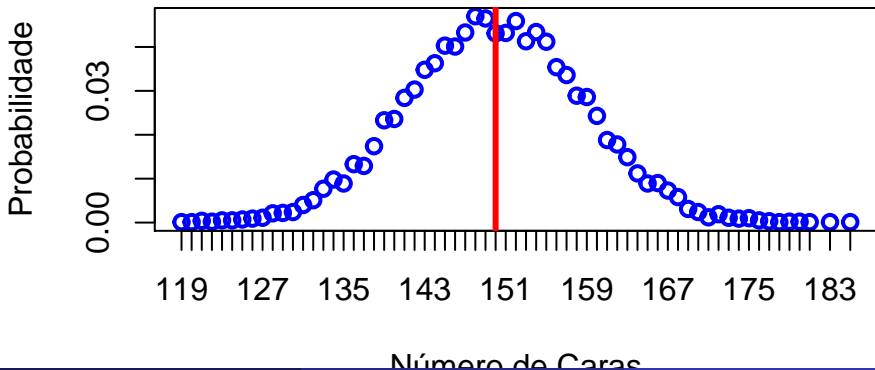
p de Jogar Caras com 30 Moedas



Probabilidade com 300 Moedas

```
titleline <- paste("p de Jogar Caras com", k, "Moedas")
plot(table(moedaProb)/n, type = "b", col = "blue",
      xlab = "Número de Caras", ylab = "Probabilidade",
      main = titleline)
abline(v = 150, col = "red", lwd = 3)
```

p de Jogar Caras com 300 Moedas



Probabilidade de Jogar Cara (geral)

```
sum(rbinom(100000, 300, pr))/100000/300
```



```
## [1] 0.5000429
```

$$p(\text{Cara}) \approx \hat{p}(\text{Cara}) = \frac{\# \text{ de CARAS observadas}}{\# \text{ de jogadas}}$$

- Lei dos Grandes Números – Lembrete
- Maior o número dos experimentos ("*Bernoulli trials*"), a média dos resultados irá convergir no valor esperado (μ) do experimento
- Valor esperado (probabilidade teórico) das CARAS – $1/2$

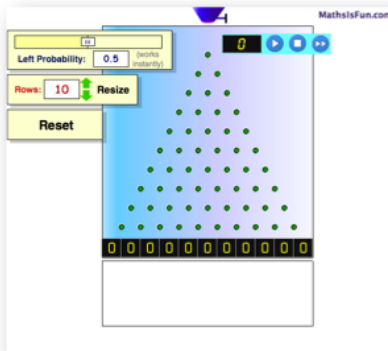
Teorema de Limite Central (CLT)

- Se repetimos um experimento muitas vezes, a probabilidade do resultado médio irá convergir a uma distribuição normal (curva de sino)
- Permite que usamos a distribuição normal como base da maioria de nossos testes estatísticos (paramétricas)




Quincunx (Quincunce)

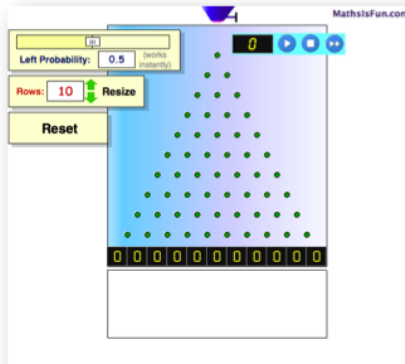
- Jogo/brinquedo em que bolas caem, batem contra pinos, pulam para direto ou esquerdo e continua caindo.
- Parecido com Pachinko mas todos os pinos estão em forma regular para que um pino forma um triangulo equilateral com os dois para baixo.
- Um paralelo com bolas do Triangulo de Pascal (com números)
- Quando cada bola bate contra um pino, tem só dois resultados possíveis
- Pode ir para esquerda ou a direita
- Segue as mesmas regras de uma variável binomial que as moedas.
- Com 1.000 bolas que pulam 10 vezes (10 fileiras), tem um total de 10.000 experimentos
- Vários sites têm exemplos do jogo.
- <http://www.mathsisfun.com/data/quincunx.html>



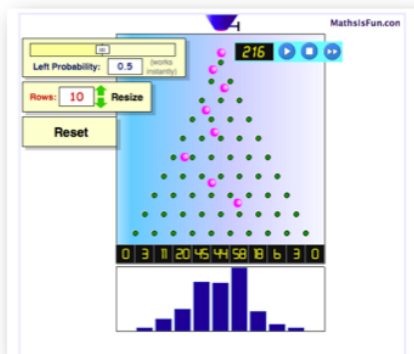
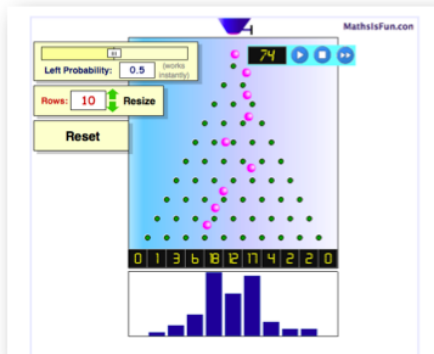
Triangulo de Pascal



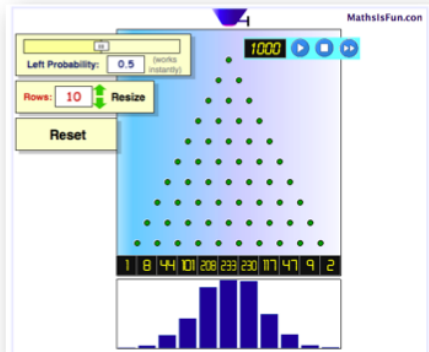
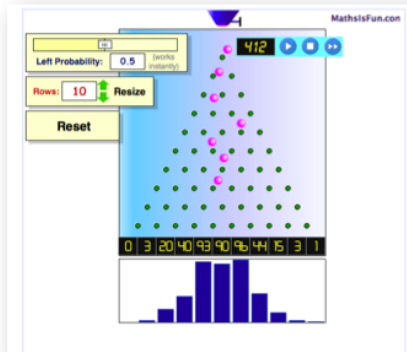
Quincunx – Início



Quincunx – 2



Quincunx – 3



Quincunx – Como Funciona

- Definir n para ser o número de fileiras e k para ser o número de vezes a bola pula para esquerda.
- Assim, $(n - k)$ deve ser a probabilidade que a bola pula para direita.
- Probabilidade da bola pula para esquerda em cada fileira: p
- Probabilidade que a bola pula a esquerda k vezes é
 - ▶ $p^k : (p_1 * p_2 \dots * p_k = p^k)$
 - ▶ Probabilidade que a bola pula a direita $(n - k)$ vezes é $(1 - p)^{(n - k)}$
- Assim, qualquer uma das 11 lugares finais tem a probabilidade de $p^k(1 - p)^{(n - k)}$
- Por causa da lei de multiplicação da interseção para eventos independentes

Probabilidade de Cair em Qualquer Posição Final

- Existem muitos caminhos para chegar na última fileira – a posição final
 - ▶ *Quantos?*
- Cada caminho representa uma das possíveis **combinações**
- Com uma probabilidade de cair igualmente para direita ou para esquerda ($p = 0,5$) e 10 fileiras ($n = 10$), quantas maneiras a bola tem para cair na *quarta* posição da esquerda?
- Existem 210 caminhos possíveis de cair na quarta posição

```
n <- 10; k <- 4; p <- 0.5  
choose(n, k) # função para combinações
```

```
## [1] 210
```

Probabilidade de Cair em Qualquer Posição Final – 2

- Probabilidade de cair neste posição é
- Número de maneiras pode cair * a probabilidade :

$$p(k; n; p) = \binom{n}{k} p^k (1 - p)^{n - k}$$

- Esta formula descreve a função binomial – a probabilidade que um evento vai ocorrer dado 2 resultados possíveis

Nosso Exemplo

```
n <- 10; k <- 4; p <- 0.5  
choose(n, k) # função para combinações
```

```
## [1] 210
```

```
dbinom(k, n, p)
```


```
## [1] 0.2050781
```

```
(quincunx <- round(dbinom(0:10, n, p), 3))
```

```
## [1] 0.001 0.010 0.044 0.117 0.205 0.246 0.205 0.117 0.044 0.010 0.001
```

Probabilidade dos Bins de um Quinquence

$p = 0.5$



Comparar Resultados com a Teoria

```
# Teoria
```

```
(quincunx <- round(dbinom(0:10, n, p), 3))
```

```
## [1] 0.001 0.010 0.044 0.117 0.205 0.246 0.205 0.117 0.044 0.010 0.001
```

```
## Dados do jogo quincunx
```


```
data.qq <- c(1, 8, 44, 101, 208, 233, 230, 177, 47, 9, 2)
```

```
(prob.qq <- round(data.qq / sum(data.qq), 3))
```

```
## [1] 0.001 0.008 0.042 0.095 0.196 0.220 0.217 0.167 0.044 0.008 0.002
```

Probabilidade dos Bins Observada

$p = 0.5$



- O que observamos é uma distribuição de amostra
- Nosso trabalho é avaliar a congruência dela com uma distribuição teórica
- Valores observados variam de amostra em amostra
- Esta variabilidade se chama: variância amostral
- Podemos fazer várias amostras e criar uma distribuição das médias (\bar{x})
- Distribuição das amostras terá uma média e variância também

- Esses existem por causa da Teorema de Limite Central

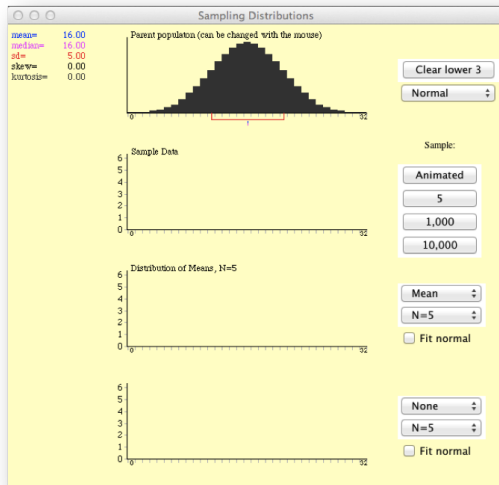
$$E(\bar{X}) = \mu$$

$$Var(\bar{X}) = \frac{\sigma^2}{n}$$

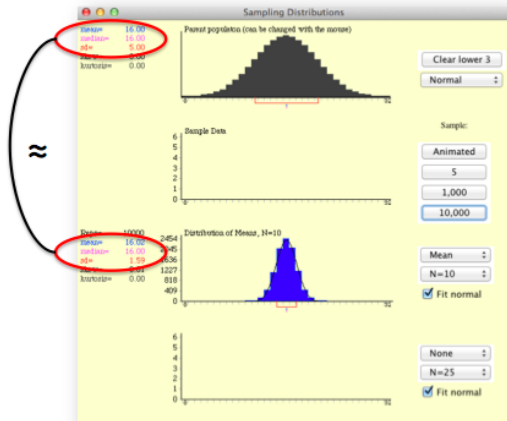
$$DP(\bar{X}) = \sqrt{Var(\bar{X})} = \frac{\sigma}{\sqrt{n}}$$

Comparar Estatísticas das Amostras a População

- Rice University – Applet das Distribuições Amostrais -Site: http://onlinestatbook.com/stat_sim/sampling_dist/index.html




Distribuição Normal



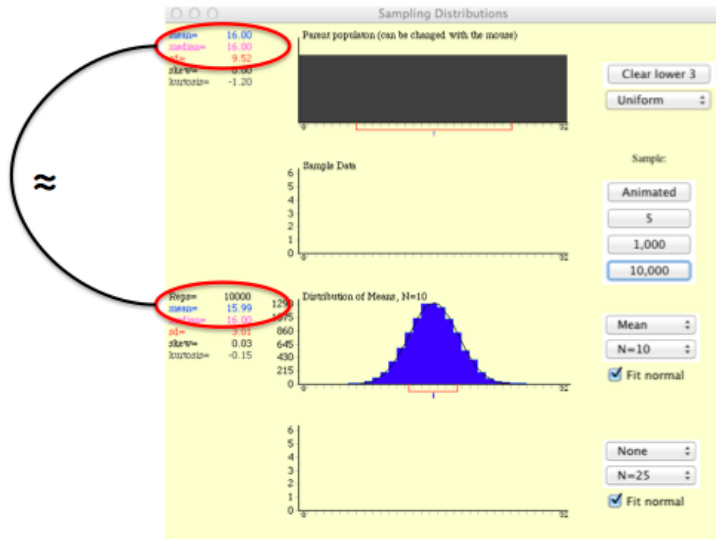
$$E(\bar{X}) = \mu; 16,02 \approx 16,00$$

$$DP(\bar{X}) = \frac{\sigma}{\sqrt{n}}; \frac{5,00}{\sqrt{10}} = 1,58 \approx 1,59$$

Distribuição Assimétrica



Distribuição Uniforme



Resumo - Distribuição Amostral – Proporções

- Teorema de Limite Central (CLT)
- Estudamos amostras e comparar nossa amostra a todas as amostras possíveis
- Distribuição Amostral de proporção binomial


$$\hat{p} \approx N\left(p, \frac{p(1-p)}{n}\right)$$

- Distribuição Amostral da Média

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

- N.B. $N(\mu, \sigma^2)$ quer dizer distribuição normal com média de μ e variância de σ^2

Vamos Imaginar que Temos uma Garrafa Cheio de Contas



- 2 Cores – Vermelho e Azul
- Não sabemos a proporção de cada cor
- Podemos fazer um experimento
 - ▶ Tirar 25 contas da garrafa e contar as cores para estimar a proporção verdadeira
 - ▶ Pode repetir isso múltiplas vezes (**muitas!!**) para estimar a proporção na garrafa
 - ▶ Usar a função `sample` em R
- *Simulação Monte Carlo*
 - ▶ Simular com o computador um evento e repetir muitas vezes
 - ▶ Estimação do valor de população
 - ▶ Aproveita da Lei de Grandes Números

- Vamos criar as contas com rep
 - ▶ Vai criar um vetor com todos as contas na garrafa
 - ▶ Não vou mostrar aqui
- Vamos selecionar 1 conta da garrafa

```
## [1] "azul"
```

- De novo

```
## [1] "vermelho"
```


Repetir Múltiplas Vezes – com replicate

- Muitas vezes – 10.000

```
trials <- 10000  
set.seed(1)  
eventos <- replicate(trials, sample(conta, 1))  
head(eventos)
```

```
## [1] "vermelho" "vermelho" "azul"      "azul"      "vermelho"
```

Determinar o Resultado da Simulação

- Usar funções `table` e `prop.table`
 - ▶ `table` – tabula os resultados
 - ▶ `prop.table` – calcula as proporções dos resultados

```
(tab <- table(eventos))
```

```
## eventos  
##      azul vermelho  
##      4704      5296
```

```
prop.table(tab)
```

```
## eventos  
##      azul vermelho  
##  0.4704  0.5296
```

- Divulgação das proporções verdadeiras
 - ▶ **azul** – 0.474
 - ▶ **vermelho** – 0.526

- replicate funciona *com substituição*
 - ▶ Tirar a conta da garrafa e repor depois
- *Sem substituição* quer dizer que não repormos a conta
 - ▶ Fica permanentemente perdido para as tabulações futuras

Distribuições de Probabilidade

- Distribuições dos números e das probabilidades são vinculados
 - ▶ Ex: Quincunce
- *Função densidade de probabilidade* $f(x) = c$
 - ▶ probabilidade que a distribuição assume um valor específico
- *Função de probabilidade cumulativa* $F(x) \leq c$
 - ▶ proporção dos valores na distribuição que ficam abaixo ou igual a um valor específico

Aplicar para Proporção das Contas Azuis

- Converter as cores em números (“azul” = 1)

```
contnum <- as.numeric(conta == "azul")
```

- Podemos acertar que o função cumulativa para “azul” (1)

- ▶ $F(1) = \frac{474}{1000} = 0.474$

- Para “vermelho” (0)

- ▶ $F(0) = \frac{526}{1000} = 0.526$

Para Variáveis Categóricas – Distribuição Cumulativa Não Intuitiva

- Melhor fazer o que fizemos com os números
- Define probabilidade de todos os estados possíveis da variável
 $\Pr(\text{vermelho}) = 0.526$ e $\Pr(\text{azul}) = 0.474$.