MAD-CB

Artigo sobre o Sistema Imune e Transcriptomica

Chaussabel et al. BMC Biology 2010, 8:84

Programação em R - Conceitos de Controle de Programa

Proposito de Modulo

Tirar algun do misterio sobre como entrar código para construir e executar os modelos estatísticos

Já Aprendemos Alguns Aspetos Importantes de Programação

- Como carregar dados dos arquivos externos em R
  - com as funções do pacote `readr` como `read_csv()`
  - com `load` do R base
- Como manusear dados com as funções de `dplyr`

Assuntos de Hoje

- Conceitos e técnicas de fluxo de controle nas programas
- Como fazer testes lógicos


INPUT
ALGORITMO
OUTPUT

Conceito Básico de Um Programa

- INPUT – Entrar alguns dados de interesse na memoria do computador
- OUTPUT – Mostrar na tela, num arquivo ou impresso o resultado das computações
- ALGORITMO – O código que torna input em output; a análise

Programas Andam da Primeira Linha até o Final

- Começam na primeira linha
- Segue sequencialmente
- Até a última linha
- Em Ordem

Fluxo de Controle

- Métodos que o programador pode usar para modificar este dinâmico básico linear
  - Repete comandos num loop
  - Mande controle para outra comando condicionalmente

Exemplo

- Este faz parte da função `lm` que controle a análise de regressão linear

```
if (!is.null(w) && !is.numeric(w))
        stop("'weights' must be a numeric vector")
```

`for` Loops (*aka* Laços)

- Loops permitem que um program fazer tarefas repetitivamente
- Existem vários tipos de loops
- Pouco precisa usar outra forma que o `for` loop
- Vamos aprender este tipo

Elementos de um Loop

- A palavra `for`
- uma variável iteradora que assumirá valores sucessivos dos elementos de um objeto
- código a ser executado dentro dos chaves (`{}`)

O Que Um Loop Faz

- Iterações com a variável iteradora
  - Assumindo todos os valores indicados
- Executar o bloco de código entre os chaves

Uso dos Loops para Calcular Valores

- Um dos usos principais para um loop é o cálculo dos valores de um
  - `data.frame`
  - `tibble`
  - vetor
  - outra estrutura de dados

Primeiro Exemplo

- Um exemplo trivial mas fácil a entender
- Queremos preencher os valores de um variável `x`
  - Colocar os valores 1 até 6 em `x`

```
x <- numeric(length = 6)  # inicializar o vetor e reservar a memoria necessária
for (i in seq(1, 6)) {
  x[i] <- i
}
x
```

```
## [1] 1 2 3 4 5 6
```

Explicação do Código

- `i` é a variável iteradora
  - Vai receber em sequência os valores 1 até 6
  - Comando `seq` (*sequência*)
- Corpo do loop colocará valor de `i` em cada elemento da variável `x` pelo assignment.

x Será Preenchida Assim

- Depois de inicialização de x
  - x = [0 0 0 0 0 0]
- 1ª vez no loop: i = 1 e x[i] terá o valor 1 pelo assignment
  - x = [1 0 0 0 0 0]
- 2ª vez no loop: i = 2 e x[i] terá o valor 2 pelo assignment
  - x = [1 2 0 0 0 0]
- 3ª vez no loop: i = 3 e x[i] terá o valor 3 pelo assignment
  - x = [1 2 3 0 0 0]
- O padrão continua até R completa a sexta rodada do loop

Exemplo 2 – Calcular Raiz Quadrado de Numéros Aleatórios

- Criar vetor dos valores aleatórios
- Calcular o raiz quadrado desses números num loop
- Começar com um número aleatório dos valores
  - Ou seja, não sabemos quantos números o program vai calcular
  - Ou quantas vezes o loop vai rodar
- Para calcular o número de rodadas necessários
  - Função `seq_along`
  - Função mede o tamanho de um vetor
- Números aleatórios baseados na distribuição "Uniforme"
  - Todos os números entre os limites têm chance igual de ser selecionados

seq_along

- Não precisa a parte "1:" da especificação do vetor porque faz si mesmo a sequência inteira dos elementos

```
seq_along(1:10)
```

```
##  [1]  1  2  3  4  5  6  7  8  9 10
```

- Retorna os 2 valores limites (1 e 10)

```r
set.seed = 1946
trials <- floor(runif(n = 1, min = 1, max = 50))
numeros <-  runif(trials, min = 1, max = 100)
quads <- numeric(length = length(numeros))
for (i in seq_along(numeros)) {
  quads[i] <- sqrt(numeros[i])
}
quads[1:10] # Mostre primeiro 10 raizes quadrados
```

```
##  [1] 7.217353 6.702688 7.134734 6.911780 7.967288 9.600600 7.404471
##  [8] 8.109612       NA       NA
```

Exemplo 3 – Criar Nova Variável num Tibble

- Amostra das cargas virais de HIV num tibble
- Queremos criar nova variável com o logaritmo de carga viral
- Vem do arquivo `counts_demo.csv`
- Precisa carregar os dados antes de criar a variável

Calculo de log10cv

```
cvdados <- read_csv("counts_demo.csv", col_names = FALSE, skip = 1)
```

```
## Parsed with column specification:
## cols(
##   X1 = col_integer(),
##   X2 = col_integer(),
##   X3 = col_integer()
## )
```

```
colnames(cvdados) <- c("copias_cv", "contagem_cd4", "contagem_cd8")
cvdados$log10cv <- rep(0, nrow(cvdados)) # inicializar nova variável
for (i in 1:nrow(cvdados)) {
  cvdados$log10cv[i] <- log10(cvdados$copias_cv[i])
}
```

```
kable(cvdados[1:10, c(1,4)])
```

copias_cv	log10cv
5200	3.716003
1947	3.289366
480000	5.681241
257313	5.410462
2585	3.412460
84	1.924279
1286	3.109241
13000	4.113943
24000	4.380211
40000	4.602060

```r
grcv <- cvdados %>%
        select(copias_cv, log10cv) %>%
        gather(tipo, valor) %>%
        ggplot(aes(x = rep(1:50, times = 2),
                   y = valor)) + geom_line() +
                   facet_grid(tipo ~ ., scales = "free")
```

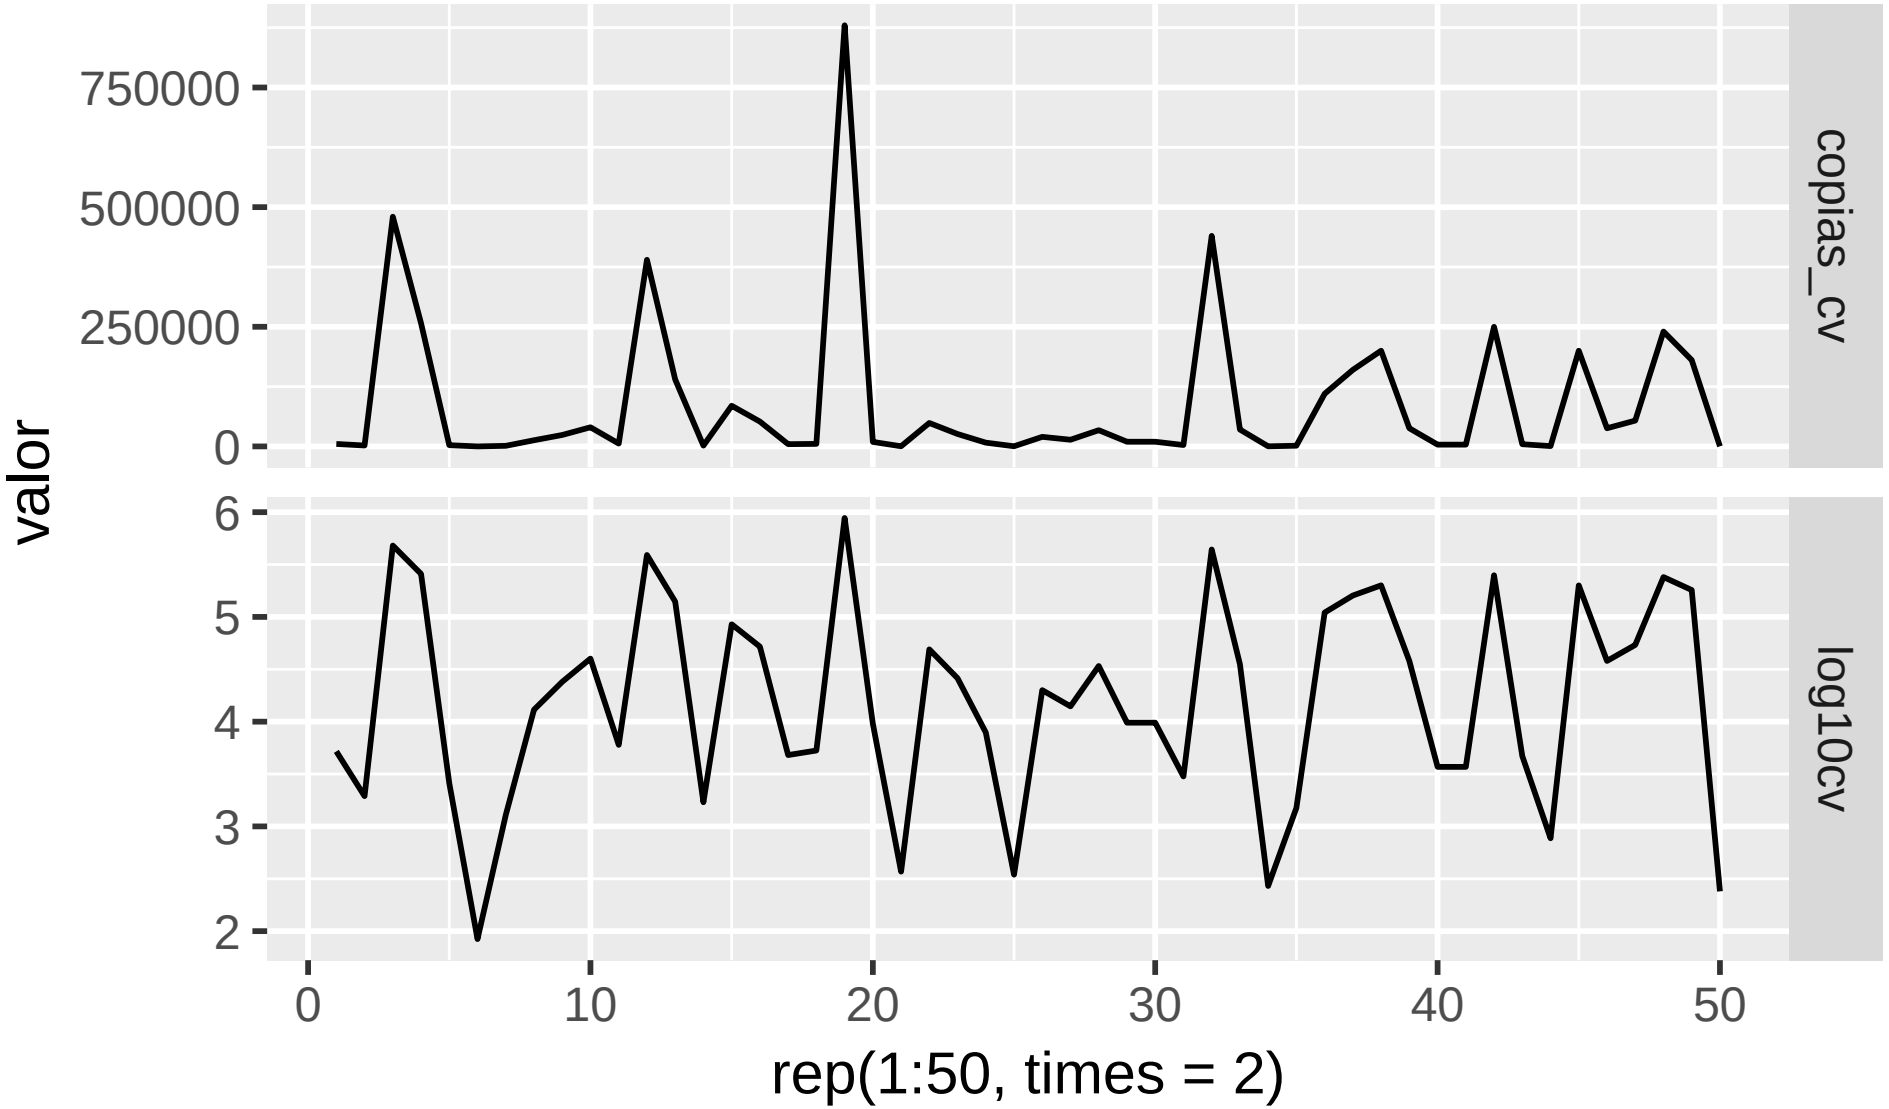
valor
750000
500000
250000
0
copias_cv
6
5
4
3
2
log10cv
0
10
20
30
40
50
rep(1:50, times = 2)

Loops Aninhados

- Pode colocar loops um dentro do outro
- Uso típico quando tem estruturas de dados hierárquicas
  - Matrizes
  - Listas dentro das listas
- **Recomendação**: Não fazer mais de 2 ou 3 loops aninhados
  - Seria difícil entender o código e rastrear o uso das variáveis iteradoras
- Pode dividir a operação em operações separadas
  - Ou criar funções para fazer os loops interiores

Exemplo de 2 Loops Aninhados

```
X <- data.frame(a = c("a", "b", "c"), b = c("d", "e", "f"),
                stringsAsFactors = FALSE)
X
```

```
##   a b
## 1 a d
## 2 b e
## 3 c f
```

```
# loop
for (i in seq_len(ncol(X))) {
  for (j in seq_len(nrow(X))) {
    print(X[j, i])
  }
}
```

```
## [1] "a"
## [1] "b"
## [1] "c"
## [1] "d"
## [1] "e"
## [1] "f"
```

Vetorização

- R é uma linguagem *vetorizada*
  - Muitas operações podem ser feito em paralelo
- Podemos especificar os valores de um vetor diretamente
  - Invés de fazer um loop

Comparar Primeiro Exemplo com a Versão Vetorizada

- O método vetorizado

```
x <- 1:6
x
```

```
## [1] 1 2 3 4 5 6
```

- Uma linha de código invés de 3

Operações Aritméticas nos Vetores sem Loops

- Pode também fazer operações aritméticas diretamente sem um loop

```
x <- 1:4
y <- 4:1 # sequências podem ir para baixo também
z <- x + y
x; y; z
```

```
## [1] 1 2 3 4
```

```
## [1] 4 3 2 1
```

```
## [1] 5 5 5 5
```

Tipos de Operações Vetorizadas

- Aritméticas
  - Adição, subtração, multiplicação e divisão
- Comparações lógicas
- Operações com matrizes
  - Operações baseados em elementos do matriz
  - Verdadeiro operações matriciais
  - Aqueles que usam %*% e outros símbolos para as matrizes

Funções

*Functions are used to **encapsulate** a sequences of expressions that are executed together to achieve a specific goal. (Peng, Kross & Anderson, Mastering Software Development in R, 2017, p. 99.)*

*Funções são usadas para **encapsular** uma sequência das expressões que são executados juntos para alcançar um objetivo específico.*

R – Uma Linguagem de Funções

- Todas os comandos em R são funções
- As vezes, temos uma tarifa específica e repetitiva que precisamos executar
  - E os autores dos pacotes não já prepararam
- Colocamos eles num função
  - Quem usa a programa pode chamar ela a vontade
- Evita que precisamos re-escrever o código cada vez que queremos usar ela

Funções Têm Argumentos

- Geralmente, funções têm argumentos que o usuário pode modificar
- Ex: função de `invlogit` na aula de regressão logística
  - Manipula um valor numérico que o usuário específica (`x`)
  - Função retorna o invlogit deste número

```
invlogit <- function(x) {
   1/(1 + exp(-x))
}
invlogit(10)
```

Família `apply` de Funções

- Grupo de funções que ajuda com a aplicação dos comandos aos vetores
  - Podem ser aplicadas a outros tipos de dados
- Todos tem o nome `xapply()`
  - Pode trocar `x` para um "l", "s", "t" ou "v"
- Apresentarei aqui a versão *simples* – `sapply()`

`sapply()`

- Aplica uma função a cada elemento de um vetor
- Retorna um vetor ou uma matriz
- `replicate` faz parte da mesma família
- Sintaxe
  - Específica um vetor (ou lista)
  - Especifica uma função a ser aplicada

2 Exemplos

```
## Aplicada a um vetor
sapply(1:10, sqrt)
```

```
##  [1] 1.000000 1.414214 1.732051 2.000000 2.236068 2.449490 2.645751
##  [8] 2.828427 3.000000 3.162278
```

```
## Aplicada a um data frame
sapply(cvdados, summary)
```

```
##         copias_cv contagem_cd4 contagem_cd8 log10cv
## Min.           84         66.0        393.0   1.924
## 1st Qu.      3700        250.8        652.0   3.568
## Median      17000        472.5        827.5   4.224
## Mean        90690        513.9        994.3   4.191
## 3rd Qu.    103800        676.0       1230.0   5.013
## Max.       880000       1603.0       2000.0   5.944
```

Funções Vetorizadas dentro de `dplyr` e `sapply()`

- `mutate`, `transmute` e `summarize` conseguem o mesmo resultado que `sapply`
  - para data frames ou tibbles
- Pode usar `sapply` dentro de um fluxo de *tidyverse*
- Para fins exploratórios, frequentemente funciona mais rápido
  - e fica mais fácil para escrever
- No exemplo, as funções de `dplyr` seleciona os primeiros 10 casos da variável `log10cv`
- Função `sapply` calcula o valor original para esses elementos da variável

```r
cvdados %>%
  select(log10cv) %>%
  slice(1:10) %>%
  sapply(function(x){10^x})
```

```
##       log10cv
##  [1,]    5200
##  [2,]    1947
##  [3,]  480000
##  [4,]  257313
##  [5,]    2585
##  [6,]      84
##  [7,]    1286
##  [8,]   13000
##  [9,]   24000
## [10,]   40000
```

Funções `map` no Pacote `purrr`

- `purrr` faz parte de *tidyverse*
- Tem família de funções chamada `map`
- Segue modelo de aplicar uma função a uma estrutura dos dados
- `map` bem integrada com os outros integrantes de *tidyverse*

Sintaxe da Família `map`

- `map(.x, .f, ...)`
- Para cada elemento de `.x`, faça `.f`
- `.x` pode ser
  - Data frame (tibble)
  - Lista
  - Vetor
- `.x` e `.f` são marcadores para objetos e funções que vai chamar

Tipos de `map`

- map() – retorna uma lista ou a mesma classe de dados que ela recebe
- ‘map_lgl() – vetores lógicos
- ‘map_chr() – vetores de caráteres
- ‘map_dbl() – vetores de números (“dbl” quer dizer dupla precisão)
- ‘map_int() – vetores de números inteiros

Recomendação

Ao início, recomendo que vocês evitam a `map` que produz listas porque vocês não têm muito prática com listas. Invés pode usar calmamente os outros quatro tipos.

2 Exemplos

```
## Mesmo sintaxe que o exemplo de sapply
map_dbl(1:10, sqrt)
```

```
##  [1] 1.000000 1.414214 1.732051 2.000000 2.236068 2.449490 2.645751
##  [8] 2.828427 3.000000 3.162278
```

```
## Aqui a função é uma função criado para este comando
map_lgl(c(1, 10, 4, 25, 100, 2000, 3, 5000), function(x) {
  x < 50
})
```

```
## [1]  TRUE  TRUE  TRUE  TRUE FALSE FALSE  TRUE FALSE
```

Testes Lógicos – `if ... then ... else`

- Existem em qualquer linguagem de computação
- Permite teste de uma condição
- Se for verdade, fazer uma coisa
- Se for falso, fazer outra coisa

if

- Versão mais simples
- Fazer um teste da condição `if`
- Se for verdade, executar o código que você colocou no bloco
- Senão, não fazer nada e o programa vai diretamente para a próxima linha

```
if (condição) {fazer algo}
## continuar com o programa
```

Exemplo de if

```
## Caso verdadeiro
x <- 4
y <- "FALSO"
if(x == 4){
  y <-  "VERDADEIRO"
}
paste("Caso:", y)
```

```
## [1] "Caso: VERDADEIRO"
```

```
## Caso falso
x <- 4
y <- "FALSO"
if(x == 5){ ## Resultado falso
  y <-  "VERDADEIRO"
}
paste("Caso:", y)
```

```
## [1] "Caso: FALSO"
```

Anote no Caso FALSO

y reteve o valor original que demos a ela porque o programa não fez nada para alterar o valor

if ... else

- Próximo nível de complexidade
- Introduzir uma ação para condição negativa
  - Uso do parâmetro `else`
- Sintaxe

```
if(condição) {
  ### fazer algo
} else {
  ### fazer outra coisa
}
```

Mesmo Exemplo neste Formato

```
## Caso verdadeiro
x <- 4
if(x == 4) {
  y = "VERDADEIRO"
} else {
  y <- "FALSO"
}
paste("Caso:", y)
```

```
## [1] "Caso: VERDADEIRO"
```

```
## Caso falso
x <- 4
if(x == 5){ ## Resultado falso
  y = "VERDADEIRO"
} else {
  y <- "FALSO"
}
paste("Caso:", y)
```

```
## [1] "Caso: FALSO"
```

Função `ifelse()`

- Função que permite que você faz todo o teste lógico dentro de um comando
- Sintaxe: `ifelse(teste, sim, não)`
- 3 Elementos do Comando
  - `teste` – teste lógico
  - `sim` – resultado para resposta VERDADEIRO
  - `não` – resultado para resposta FALSA
- `ifelse` muito compacto em código
- Execução rápido

Mesmo Exemplo – De Novo

```
x = 4

## Caso Verdadeiro
y <- ifelse(x == 4, y <- "VERDADEIRO", "FALSO")
paste("Caso:", y)
```

```
## [1] "Caso: VERDADEIRO"
```

```
## Caso Falso
y = ifelse(x == 5, "VERDADEIRO", "FALSO")
paste("Caso:", y)
```

```
## [1] "Caso: FALSO"
```